

序号	页码	原文	更正
1	12	<p>对 <math>w_j</math> 求偏导数并令其为 0, 可得</p> $w_j = \frac{\sum_{i=1}^N x_i y_i}{\sum_{i=1}^N x_i^{j+1}},$ <p><math>j=0,1,2,\dots,M</math></p> <p>于是求得拟合多项式系数 <math>w_0^*, w_1^*, \dots, w_M^*</math>.</p>	<p>这一问题可用最小二乘法求得拟合多项式系数的唯一解, 记作 <math>w_0^*, w_1^*, \dots, w_M^*</math>. 求解过程这里不予叙述, 读者可参阅有关材料.</p>
2	77	$F(-x+\mu)-\frac{1}{2}=-F(x-\mu)+\frac{1}{2}$	$F(-x+\mu)-\frac{1}{2}=-F(x+\mu)+\frac{1}{2}$
3	161	$=\log P(Z Y,\theta^{(i+1)})=0 \quad (9.23)$	$=\log \left[ \sum_Z P(Z Y,\theta^{(i+1)}) \right]=0 \quad (9.23)$
4	198	$W_i(y_{i-1}, y_i   x) = \sum_{k=1}^K w_k f_k(y_{i-1}, y_i, x, i)$ <p>(11.23)</p>	$W_i(y_{i-1}, y_i   x) = \sum_{k=1}^K w_k f_k(y_{i-1}, y_i, x, i)$ <p>(11.23)</p>
5	14	<p>第 13,14 行</p> <p>可以假设复杂的模型有较大的先验概率, 简单的模型有较小的先验概率.</p>	<p>第 13,14 行</p> <p>可以假设复杂的模型有较小的先验概率, 简单的模型有较大的先验概率.</p>
6	141	(0.0715,0.0715,0.0715,0.0715,0.0715,0.0715,0.1666,0.1666,0.1666,0.0715)	(0.07143,0.07143,0.07143,0.07143,0.07143,0.07143,0.16667,0.16667,0.16667,0.07143)
7	43	第 8 行 (参阅图 3.8)	第 8 行 (参阅图 3.5)
8	119	<p>式(7.73)</p> $f * g \bullet \sum_{i=1}^m \sum_{j=1}^l \alpha_i \beta_j K(x_i, z_j)$	<p>式(7.73)</p> $f * g = \sum_{i=1}^m \sum_{j=1}^l \alpha_i \beta_j K(x_i, z_j)$
9	163	式(9.28)	该编号移到 164 页第一公式后

10	222	倒数第 9 行 式(B.23)	倒数第 9 行 式(B.24)
11	35	表 2.2 第 6 列  4  $x_3$  2 0 2 0	表 2.2 第 6 列  4  $x_3$  1 0 3 -2
12	115	第 4 行 损失函数 $[y_i(wx_i + b)]_+$	第 4 行 损失函数 $[-y_i(wx_i + b)]_+$
13	63	<p>5.2.3 信息增益比</p> <p>信息增益值的大小是相对训练数据集而言的, 并没有绝对意义. 在分类问题困难时, 也就是训练数据集的经验熵大的时候, 信息增益值会偏大. 反之, 信息增益值会偏小. 使用信息增益比 (information gain ratio) 可以对这一问题进行校正. 这是特征选择的另一准则.</p> <p>定义 5.3 (信息增益比) 特征 <math>A</math> 对训练数据集 <math>D</math> 的信息增益比</p> <p><math>g_R(D, A)</math> 定义为其信息增益 <math>g(D, A)</math> 与训练数据集 <math>D</math> 的经验熵 <math>H(D)</math> 之比</p> $g_R(D, A) = \frac{g(D, A)}{H(D)} \quad (5.10)$	<p>5.2.3 信息增益比</p> <p>以信息增益作为划分训练数据集的特征, 存在偏向于选择取值较多的特征的问题. 使用信息增益比 (information gain ratio) 可以对这一问题进行校正. 这是特征选择的另一准则.</p> <p>定义 5.3 (信息增益比) 特征 <math>A</math> 对训练数据集 <math>D</math> 的信息增益比 <math>g_R(D, A)</math> 定义为其信息增益 <math>g(D, A)</math> 与训练数据集 <math>D</math> 关于特征 <math>A</math> 的值的熵 <math>H_A(D)</math> 之比, 即</p> $g_R(D, A) = \frac{g(D, A)}{H_A(D)} \quad (5.10)$ <p>其中</p> $H_A(D) = - \sum_{i=1}^n \frac{ D_i }{ D } \log_2 \frac{ D_i }{ D }$ <p><math>n</math> 是特征 <math>A</math> 取值的个数.</p>

14	114	<p>证明 可将最优化问题(7.63)写成问题 (7.60) ~ (7.62). 令</p> $1 - y_i(w \square x_i + b) = \xi_i ,$ $\xi_i \geq 0$ <p>(7.64)</p> <p>则 <math>y_i(w \square x_i + b) \geq 1</math>. 于是 <math>w, b, \xi_i</math> 满足约束条件(7.61)~(7.62). 由(7.64)有 <math>[1 - y_i(w \square x_i + b)]_+ = [\xi_i]_+ = \xi_i</math>, 所以最优化问题(7.63)可写成</p>	<p>证明 可将最优化问题(7.63)写成问题 (7.60) ~ (7.62). 令</p> $[1 - y_i(w \square x_i + b)]_+ = \xi_i$ <p>(7.64)</p> <p>则 <math>\xi_i \geq 0</math>, 式 (7.62) 成立. 由式 (7.64), 当 <math>1 - y_i(w \square x_i + b) &gt; 0</math> 时, 有</p> $y_i(w \square x_i + b) = 1 - \xi_i ;$ <p>当 <math>1 - y_i(w \square x_i + b) \leq 0</math> 时, <math>\xi_i = 0</math>, 有</p> $y_i(w \square x_i + b) \geq 1 - \xi_i .$ <p>故式 (7.61) 成立. 于是 <math>w, b, \xi_i</math> 满足约束条件(7.61)~(7.62). 所以最优化问题(7.63)可写成</p>
15	第 159 页	利用 Jensen 不等式(Jensen inequality)	<p>利用 Jensen 不等式(Jensen inequality) ①</p> <p>脚注① 这里用到的是</p> $\log \sum_j \lambda_j y_j \geq \sum_j \lambda_j \log y_j ,$ <p>其中 <math>\lambda_j \geq 0, \sum_j \lambda_j = 1</math>.</p>
16	第 163 页	<p>(原稿)</p> <p>那么, 完全数据的对数似然函数为</p> $\log P(y, \gamma   \theta) = \sum_{k=1}^K n_k \log \alpha_k + \sum_{j=1}^N \gamma_{jk} [\log(\frac{1}{\sqrt{2\pi}}) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2]$	
		<p>(修改稿) 加大括号</p> <p>那么, 完全数据的对数似然函数为</p> $\log P(y, \gamma   \theta) = \sum_{k=1}^K \{n_k \log \alpha_k + \sum_{j=1}^N \gamma_{jk} [\log(\frac{1}{\sqrt{2\pi}}) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2]\}$	
	第 163 页	<p>(原稿)</p> <p>2. EM 算法的 E 步: 确定 <math>Q</math> 函数.</p> $Q(\theta, \theta^{(i)}) = E[\log P(y, \gamma   \theta)   y, \theta^{(i)}]$ $= E\{\sum_{k=1}^K n_k \log \alpha_k + \sum_{j=1}^N \gamma_{jk} [\log(\frac{1}{\sqrt{2\pi}}) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2]\}$	

		<p>(修改稿) 加大括号</p> <p>2. EM 算法的 E 步: 确定 <math>Q</math> 函数.</p> $Q(\theta, \theta^{(i)}) = E[\log P(y, \gamma   \theta)   y, \theta^{(i)}]$ $= E\left\{\sum_{k=1}^K \{n_k \log \alpha_k + \sum_{j=1}^N \gamma_{jk} [\log(\frac{1}{\sqrt{2\pi}}) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2]\}\right\}$
	第 164 页	<p>(原稿)</p> $Q(\theta, \theta^{(i)}) = \sum_{k=1}^K n_k \log \alpha_k + \sum_{k=1}^N \hat{\gamma}_{jk} [\log(\frac{1}{\sqrt{2\pi}}) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2] \quad (9.29)$ <p>(修改稿) 加上大括号, 第二个和号的求和指标由 <math>k</math> 改为 <math>j</math></p> $Q(\theta, \theta^{(i)}) = \sum_{k=1}^K \{n_k \log \alpha_k + \sum_{j=1}^N \hat{\gamma}_{jk} [\log(\frac{1}{\sqrt{2\pi}}) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2]\}$ <p>(9.29)</p>
17	第 73 页 算 法 5.7	<p>(原稿)</p> <p>(4) 自上而下地访问内部结点 <math>t</math>, 如果有 <math>g(t) = \alpha</math>, 进行剪枝, 并对叶结点 <math>t</math> 以多数表决法决定其类, 得到树 <math>T</math></p> <p>(修改稿)</p> <p>(4) 对 <math>g(t) = \alpha</math> 的内部结点 <math>t</math> 进行剪枝, 并对叶结点 <math>t</math> 以多数表决法决定其类, 得到树 <math>T</math></p>
18	第 73 页 算 法 5.7	<p>(原稿)</p> <p>(6) 如果 <math>T</math> 不是由根结点单独构成的树, 则回到步骤(4).</p> <p>(修改稿)</p> <p>(6) 如果 <math>T_k</math> 不是由根结点及两个叶结点构成的树, 则回到步骤(2); 否则令 <math>T_k = T_n</math></p>
19	第 205 页 算 法 11.2	<p>(原稿)</p> <p>(6) 计算 <math>g_{k+1} = g(w^{(k+1)})</math>, 若 <math>g_k = 0</math>, 则停止计算;</p> <p>(修改稿)</p> <p>(6) 计算 <math>g_{k+1} = g(w^{(k+1)})</math>, 若 <math>g_{k+1} = 0</math>, 则停止计算;</p>
20	第 200 页	<p>(原稿)</p> $\beta_i(y_i   x) = M_i(y_i, y_{i+1}   x) \beta_{i-1}(y_{i+1}   x) \quad (11.30)$ <p>(修改稿)</p> $\beta_i(y_i   x) = M_{i+1}(y_i, y_{i+1}   x) \beta_{i+1}(y_{i+1}   x) \quad (11.30)$

21	第 196 页	(原稿) 倒数第 11 行 $\lambda_2 = 0.5$
		(修改稿) $\lambda_2 = 0.6$
22	第 208 页	(原稿) 第 9 行 $\delta_2(1) = \max\{1 + \lambda_2 t_2, 0.5 + \lambda_4 t_4\} = 1.6$ $\Psi_2(1) = 1$
		(修改稿) $\delta_2(1) = \max\{1 + \lambda_2 t_2 + \mu_3 s_3, 0.5 + \lambda_4 t_4 + \mu_3 s_3\} = 2.4$ $\Psi_2(1) = 1$
		(原稿) 第 12 行 $\delta_3(1) = \max\{1.6 + \mu_5 s_5, 2.5 + \lambda_3 t_3 + \mu_3 s_3\} = 4.3$ $\Psi_3(1) = 2$
		(修改稿) $\delta_3(1) = \max\{2.4 + \mu_5 s_5, 2.5 + \lambda_3 t_3 + \mu_3 s_3\} = 4.3$ $\Psi_3(1) = 2$
		(原稿) 第 13 行 $\delta_3(2) = \max\{1.6 + \lambda_1 t_1 + \mu_4 s_4, 2.5 + \lambda_5 t_5 + \mu_4 s_4\} = 3.2$ $\Psi_3(2) = 1$
		(修改稿) $\delta_3(2) = \max\{2.4 + \lambda_1 t_1 + \mu_4 s_4, 2.5 + \lambda_5 t_5 + \mu_4 s_4\} = 3.9$ $\Psi_3(2) = 1$
23	第 156 页式	(原稿) 式(9.5)左端 $\mu^{(i+1)}$
		(修改稿) $\mu_j^{(i+1)}$
24	第 198 页	(原稿) 这样, 给定观测序列 $x$ , 标记序列 $y$ 的非规范化概率可以通过 $n+1$ 个矩阵的乘积 $\prod_{i=1}^{n+1} M_i(y_{i-1}, y_i   x)$ 表示,
		(修改稿) 这样, 给定观测序列 $x$ , 相应标记序列 $y$ 的非规范化概率可以通过该序列 $n+1$ 个矩阵适当元素的乘积 $\prod_{i=1}^{n+1} M_i(y_{i-1}, y_i   x)$ 表示.

25	第 200 页	<p>(原稿)</p> $\alpha_i^T(y_i   x) = \alpha_{i-1}^T(y_{i-1}   x) M_i(y_{i-1}, y_i   x), \quad i = 1, 2, \dots, n+1 \quad (11.27)$ <p>(原稿)</p> $\beta_i(y_i   x) = M_i(y_i, y_{i+1}   x) \beta_{i+1}(y_{i+1}   x) \quad (11.30)$
		<p>(修改稿)</p> $\alpha_i^T(y_i   x) = \alpha_{i-1}^T(y_{i-1}   x) [M_i(y_{i-1}, y_i   x)], \quad i = 1, 2, \dots, n+1 \quad (11.27)$ <p>(修改稿)</p> $\beta_i(y_i   x) = [M_i(y_i, y_{i+1}   x)] \beta_{i+1}(y_{i+1}   x) \quad (11.30)$
26	第 29 页, 倒数第 2 行公式	<p>(原稿) (公式右边的 <math>x</math> 少了下标 <math>i</math>)</p> $\min_{w,b} L(w,b) = - \sum_{x_i \in M} y_i(w \bullet x + b)$ <p>(修改稿)</p> $\min_{w,b} L(w,b) = - \sum_{x_i \in M} y_i(w \bullet x_i + b)$